





공간 소리를 듣고 판단하는 모델

마이크의 관측을 LLM의 답변으로 연결하는 조건



공간 오디오 이해의 목표




α 방위각 azimuth

β 고도각 elevation

r 거리 distance


음원의 종류와 위치: 방위각·고도각·거리

두 채널 관측 신호




■ 같은 음원에서 출발한 소리, 서로 다른 두 관측

경로 차이와 시간차




경로 차이에 따라 달라지는 도달 시간차

잔향과 음원 혼합



직접음에 더해지는 반사음과 다른 음원의 기여


마이크 배열 기하



■ 같은 음원 위치에서도 마이크 간격에 따라 달라지는 시간차

GCC-PHAT: 두 신호에서 시간차를 찾는다

두 채널 관측




구간 내 시간 (ms)

$$\tau_{21} = t_2 - t_1$$

PHAT 가중

$$G_{21} = X_2 X_1^*$$

교차스펙트럼 크기



주파수 f (kHz)


$$\Phi_{21} = \frac{G_{21}}{\max(|G_{21}|, \epsilon)}$$

크기로 나누고 위상은 유지

시간차별 일치 점수

$$C_{21} = \mathcal{F}^{-1}\{\Phi_{21}\}$$

$$\hat{\tau}_{21} = -1.25 \text{ ms}$$



시간차 τ_{21} (ms)


전체 곡선을 SRP에 전달

공유 기하에서 계산한 무방향 합성 신호 · $\tau_{21}=t_2-t_1$ · 점수는 표시용 정규화


시간차별 일치 점수를 계산한다. 최대점은 지연 추정값이고, 전체 곡선은 SRP의 입력이다.

지연 하나에 대응하는 좌표는 여러 개다

한 지연에 대응하는 위치들



거리 차이 $d_1 - d_2$ 는 같다




$$\tau_{21} = (d_2 - d_1)/c = -1.253 \text{ ms}$$

지연이 같은 후보 집합 · $\|p - M_2\| - \|p - M_1\| = c \tau_{21}(p_s)$

■ GCC-PHAT로 얻은 **지연 하나**는 가능한 위치를 **쌍곡선으로 좁힌다**.

후보 좌표가 예측한 지연에서 상관값을 읽는다



A는 생성에 사용한 음원 위치

거리 → 기대 지연

$$p_A = (0.6, 1.6)$$

$$(1.601 - 2.030)/343$$


$$\tau_{21} = -1.253 \text{ ms}$$

$$p_B = (-0.4, 1.3)$$

$$(1.671 - 1.324)/343$$

$$\tau_{21} = +1.012 \text{ ms}$$

그 지연의 상관값




$$R_{21}(p) = C_{21}^{\text{PHAT}}(\tau_{21}(p))$$

좌표 $p \rightarrow$ 거리 차이 $\rightarrow$ 기대 지연 $\tau_{21}(p) \rightarrow$ 쌍 응답 $R_{21}(p)$

SRP는 후보 위치의 예상 지연이 관측 상관과 얼마나 맞는지 평가한다.


쌍별 응답을 합하고 가장 높은 좌표를 고른다



추가 마이크 $M_3 = (-0.5, 2.8) \text{ m}$ · $\mathcal{P}$: 같은 높이의 1 cm 후보 격자

GCC-PHAT → 후보별 점수 → 쌍 합산 → 최대 좌표, 이것이 SRP의 계산 흐름이다.



Neural-SRP: 쌍별 공간 응답을 학습한다



$$\text{고정 계산 } R_{ij}(p) = C_{ij}^{\text{PHAT}}(\tau_{ij}(p)) \cdot \text{학습 목표 } Y_{ij}(p) = \exp \left[- \left(\frac{|\tau_{ij}(p) - \tau_{ij}(p_s)|}{\sigma_\tau} \right)^2 \right]$$

쌍의 공간 응답을 학습하고, 쌍 합산과 최대점 선택은 유지한다.

학습한 쌍별 응답을 합치면 위치 피크가 달라진다




왼쪽: NeuralSRP+ · 오른쪽: SRP. 원문 패널 재배치, 공유 x축은 두 패널 아래에 표시.

■ 쌍별 공간 응답을 학습하고 합산하는 설계가 위치 피크를 바꾼 정성 예시다.

학습한 응답의 효과는 실녹음 적응 조건에서 확인한다

Recorded 4 · 한 방의 정지 단일 음성


평균 위치 오차 (m) ↓



실녹음 250개로 추가 학습 · 시험 2,500개 · $T_{60} = 800$ ms

250개 실녹음으로 추가 학습한 조건에서 SRP보다 오차가 작았다.

좌표 다음에 무엇을 전달해야 하는가?



표현에 남은 정보는 인코더를 고정한 판독과 전체 미세조정을 구별해 확인

LLM에 답변을 맡기려면 **사건·공간·시간을 담은 표현**도 필요하다.

공간 QA에서 기존 Audio-LM 확장과 동적 장면으로

2024.02

공간 QA 연결

BAT

공간 E → P → LM

정적 장면의 관계

2025.09

같은 시기의 분화

DSPAST · OWL

과제별 단서 · 기하 감독

Motion: JSON → LM

명시적 사건·좌표 시계열

2025.10–2026.06

기존 Audio-LM 확장

Sci-Phi · PhaseCoder
TWNM* · Spatial-Omni

의미 경로 + 공간 경로

기하 · 음원 결속 · 이식

2026.02–06

동적 장면의 표현

Dynamic QA
ST-AudioLM

시간·궤적을 토큰에

BAT 기반을 각각 확장

최초 공개 시점 · 연구 질문별 묶음 | *TWNM의 FOA·SAPO는 2026.05 v3

공간 QA 연결 → 표현·전달 방식의 분화 → 기존 Audio-LM 확장 → 시간 구조

언어로 기술해 넘길까, 오디오 표현을 직접 연결할까?

Motion · 2025 학습된 지각 E

예측 속성 JSON


기존 텍스트 토큰



OWL · 2025 학습된 지각 E

연속 표현 정렬 P


연속 오디오 Z



연속 임베딩을 입력에 추가 ≠ hidden width·어휘 수 확대

LM에 들어가는 정보의 형식과 LM 가중치를 학습하는 방식은 서로 다른 선택이다.

오디오 표현은 어떻게 LLM의 입력이 되는가



연속 오디오 토큰을 입력 시퀀스에 추가 · 어휘 수와 임베딩 폭은 별개

연속 오디오 입력의 연결과 LM 가중치의 적응은 별개다. LoRA는 후자의 한 방법이다.

LoRA는 LLM의 입력 처리 방식을 조정한다

P의 출력과 질문

$$W = W_0 + \frac{\alpha}{r}BA$$

답변 생성


오디오 Z




질문



h



후속 층·출력 헤드




기존 어휘
확률 분포

P는 입력을 정렬하고 · LoRA는 LLM이 입력을 처리하는 선형층을 적응한다


P는 연속 오디오 토큰을 만들고, LoRA는 이를 처리하는 LLM 가중치를 적응한다.

LLM 전에 무엇이 읽혀야 하는가?

위치만 이동



같은 알람



종류 = · 위치 ↔

종류만 교체




같은 좌표




종류 ↔ · 위치 =

순서만 교환



같은 두 사건






순서 AB ↔ BA

후속 실험 제안. = 는 유지, ↔ 는 조건에 맞는 변화. H는 인코더 표현.

같은 소리의 **종류는 유지**하고, 바뀐 **위치와 순서**는 읽혀야 한다.

학습 과제는 어떤 관계를 남기게 하는가?



관측 관계와 학습 목표의 도해 · 각 목표의 효과는 후속 판독 실험으로 검증


위치·사건·방 정보가 남도록 과제를 설계하고, 무엇을 읽을 수 있는지 따로 검사한다.

사건과 방향이 남았는지는 고정 인코더로 읽어 본다

LP · 인코더 고정, 사건/방향 선형 판독기 각각 학습

사건 정확도 (%) ↑

방위각 오차 (°) ↓




4채널·정지·비중첩 · noisy split 38.8시간 사전학습 · clean 레이블로 LP

인코더를 고정한 판독에서 **사건과 방향 정보의 접근성**을 확인한다.

BAT: 공간 지각의 표현을 질문의 입력으로 바꾼다


일반 오디오 언어화

Pengi · 2023



BAT · 2024

공간 관측을 읽는 E와 공간 QA



BAT의 전환은 **공간 속성을 배우던 인코더의 표현을 언어 질문에 재사용**한 데 있다.

BAT 2024: 공간 입력은 관계 질문에 기여했는가?

SpatialSoundQA · 두 음원의 관계 Yes/No · 같은 최종 BAT

관계 질문 · 평균 BA (%) ↑

P · 질문만



B + P · 바이노럴 + 질문




이 평가에서 **바이노럴 입력을 제공한 조건**의 관계 QA 점수가 더 높다.

같은 연결 틀에서, 인코더가 배워야 할 것을 바꾼다



DSpAST · 특징과 과제별 선택



OWL · 기하 보조 사전학습



같은 공간 QA 틀에서도 어떤 신호 단서를 넣고 어떤 목표로 E를 학습하는지가 다르다.


DSPAST 2025: 같은 LM 연결에서 인코더를 비교한다

합성 바이노럴 · single-stage BAT · 전체 질문 5 epochs, LoRA, greedy decoding

방향 정확도 (%) ↑
Type D · 8범주

DER (%) ↓
거리 오차 > 0.5 m

관계 평균 BA (%) ↑
Type E




LLM 인터페이스를 맞춘 비교에서 **인코더 설계·사전학습의 기여**를 읽는다.

OWL 2025: 기하 감독은 위치 추정에 기여했는가?

BiDepth 합성 평가 · 추론 입력은 바이노럴 · 기하 지도 loss 비교

방향 MAE (°) ↓

거리 DER (%) ↓



DER: 거리 오차가 0.5 m를 넘는 비율


이 표의 개입은 **인코더의 geometry loss**다. 어댑터·LoRA·CoT 효과를 뜻하지 않는다.

Motion 2025: 지각 결과를 JSON으로 넘기는 대안

학습한 지각 결과 → JSON → 같은 Qwen-7B 추론 모델 · QA 정확도 (%) ↑


DoA-trajectory

Overall



AGM 결합 경로의 **전체 QA**는 개선됐지만 **방향·궤적 질문**은 낮아졌다.

기존 Audio-LM을 살리고 공간 경로를 붙이는 문제



Sci-Phi · 2025.10

기존 의미 경로를 고정하고 확장

PhaseCoder · 2026.01

채널 위상과 마이크 좌표를 연결

TWNM · v3 2026.05

의미·공간의 밀집 특징을 융합


Spatial-Omni · 2026.06

여러 기반 모델에 단계적으로 이식

공통 설계 문제의 비교 · 서로를 순차 개량한 모델이라는 뜻은 아님

새 공간 경로를 붙인 뒤에는 **공간 정보의 기여와 기존 의미 능력**을 함께 확인해야 한다.


Sci-Phi 2025: 기존 의미 경로 옆에 공간 경로를 학습한다



공간 경로는 적응하고, 기존 mono 의미 인코더·projector·audio LoRA는 고정한다.

기존 의미 경로는 고정하고 공간 encoder·projector·LoRA를 적응한다.

PhaseCoder: 특정 마이크 배열에 묶이지 않는 공간 입력



원문 Fig. 2 상단: 네 채널 파형. x축 시간(ms), y축 amplitude.

공간 경로

다채널 오디오
+ 마이크 좌표

의미 경로

기존 mono 오디오
+ 텍스트 질문

명칭의 범위

배열 변화에 대응
좌표는 계속 필요


PhaseCoder의 추론 입력에는 **다채널 오디오와 마이크 좌표**가 함께 필요하다.

PhaseCoder: 공간 QA와 목표 발화 전사의 절충

Gemma · Task 2 관계 Yes/No 정확도 (%) ↑ · 두 발화를 비중첩 연결

Synthetic 정확도 (%) ↑


RSL2019 정확도 (%) ↑



반례 · RSL Task 4 mean WER: 42.90 → 48.41 (낮을수록 좋음)

관계 QA와 공간 지정 목표 발화 전사는 별도 과제로 확인해야 한다.

Spatial-Omni: 여러 기반 모델에 공간 경로를 이식한다



두 입력 경로

FOA → 공간 encoder

W → 의미 encoder

학습 순서

projector 정렬

→ LoRA 결합

→ 공간 경로 적응

Fig. 1 오른쪽 경로 크롭. 영상은 기존 backbone의 선택 경로이며 공간 QA의 추가 관측이 아니다.

projector 정렬 → LLM LoRA → 공간 경로 적응으로 학습 문제를 나눈다.


Spatial-Omni: 추가한 공간 입력의 기여를 확인한다

SO-Bench · 같은 7B 계열 · greedy decoding · 점수는 모두 % (높을수록 좋음)

EAzi (%) ↑
방위각 오차 $\leq 20^\circ$


IS-Loc (%) ↑
위치로 음원 식별

RLR (%) ↑
상대 좌우



이 zero-spatial 비교는 **공간 입력 기여의 근거**이며 제거 시점·checkpoint 공유는 미명시다.

TWNM v3: 의미와 공간을 같은 음원에 묶는다



v3: 공간 encoder 학습·적응 → projector 정렬 → SFT → SAPO.

| **source slots로 감독**하지만, LLM에는 의미 경로와 결합한 **dense 특징**을 보낸다.

토큰을 결합하는 설계에 따라 결과가 달라졌다

TWNM · ASA 평가 · semantic-judge · 원문 보고 Overall · 최종 SAPO 이전

Overall (%) ↑


P0 · Single MLP



P1 · Dual Tower



P2 · Dense Hybrid



동일 checkpoint·학습 예산의 완전 통제는 미명시 · 별도 exact-MCQA 점수와 채점법이 다름

어댑터에서는 어떤 특징을 나누고 결합하는가도 학습 설계의 일부다.


TWNM v3: 연결 이후에는 답변 학습 목표도 달라진다

ASA benchmark · 최대 3음원 합성 FOA · exact MCQA · 단일 실행 · 정확도 (%) ↑

L1 · 지각

L2 · 관계 연결

L3 · 복합 질의




복합 질의의 개선과 기초 지각·관계 연결의 소폭 하락이 함께 나타난다.

움직임을 묻기 시작하면 시간 구조가 필요하다

Motion · 2025.09

예측 속성을 명시



event · azimuth(t) · distance(t)

JSON → 텍스트 LM

추론 LM 연결은 training-free

Dynamic QA · 2026.02

시간 인식 특징을 연결



시간 특징 → Q-Former

오디오 토큰 → Qwen3

구간 mask · thinking 비교

ST-AudioLM · 2026.06

궤적을 지도하고 토큰화



사건 · 활동 · 방향 · 거리


의미 1 + 시간 40 → LM

같은 41-token 기준선과 비교

상단 궤적은 설명용 · Dynamic QA와 ST-AudioLM은 BAT 기반을 각각 확장

정적 위치 다음에는 **어느 음원이 언제 움직였는지**를 전달하는 방식이 쟁점이 된다.

시간 평균은 서로 다른 이동을 같게 만들 수 있다



교육용 반례 · 순서 없는 평균에 한정하며 모든 전역 토큰의 한계를 뜻하지 않음

이동 질문에 답하려면 **사건·위치·시간의 대응을 전달하는 표현**이 필요하다.

Dynamic QA 2026: 질문에 필요한 시간 구간을 고른다

합성 이동 stereo · Qwen3-4B · Overall 정확도 (%) ↑ · GT는 정답 구간 참고 조건


Overall 정확도 (%) ↑



구간 밖을 0으로 masking · 같은 구간의 간섭 음원을 분리하는 것은 아님

masking과 thinking의 **결합 효과는 조건에 따라 다르며 전체 개선 폭은 제한적**이다.

ST-AudioLM 2026: 시간별 음원 상태를 토큰으로 남긴다



왼쪽: 궤적 지도 학습. 오른쪽: 고정 ST-Audio Encoder + 학습하는 connector·LoRA.

고정 인코더의 **의미·궤적 토큰**을 학습하는 connector와 LoRA로 연결한다.

ST-AudioLM: 같은 41개 토큰에서도 시간 표현이 다르다


ST-AudioQA Type C · FOA, OLMo2, 41-token 인터페이스 · controlled-answer accuracy (0-100) ↑

시간 관계
Temp. rel.

이동 조건
Move-spat.

궤적 관계
Traj. rel.

평균




- Spatial-AST-FOA + OLMo2
- ST-AudioLM

같은 41-token 인터페이스에서도 **시간 구조를 배운 표현**의 평균 성과가 달랐다.

읽히는 정보가 답에도 쓰이는가?


보고된 관측 위치



각 문헌의 관측 위치를 겹쳐 그린 지도. E: 인코더 · P: adapter · Q: 질문.

판독, 자극 반응, token 비교, 답변 변화는 서로 다른 증거다.

문장으로만 넘기면 공간 단서가 얼마나 남는가?



문장에 남은 정보

소리 · 사건


따로 확인할 정보

방향 · 미세한 시간 관계

STAR-Bench Fig. 1의 audio/caption 비교 패널.

평가하려는 단서가 **설명문에 보존되는지**부터 확인한다.


같은 표현에서도 속성마다 읽히는 정도가 다르다



의미 · 위치 · 방의 정규화 판독 점수. 원문 축과 요인 범례 유지.

고정 인코더의 **같은 판독 규칙**으로 의미·위치·방 정보의 접근성을 비교한다.

같은 잡음에서 표적 위상을 바꾸고 표현을 읽는다




설명용 합성 파형(시간·진폭 임의 단위) · 고정 인코더 · final-block 평균 pooling

■ 측정값은 **잡음 기준 임베딩 거리비**이며, 인간의 탐지 역치와 구별한다.

표현의 단서 반응은 LLM의 답변 사용과 다르다

500 Hz · SNR -14 dB · 고정 인코더, 모델별 전처리 · 100 seeds/cell

표현 거리비 지표 (dB)



* 원표의 FDR 보정 표시($q = 0.05$) · 양수: 역위상 조건의 표현 거리가 더 큼

이 표현 거리 반응만으로 **LLM이 같은 단서를 사용한다**고 말할 수는 없다.

현장 응답 대상은 전체 시스템으로 검증한다


기기에게 건넨 말인가? · WearVox · Side Talk Rejection 정확도 (%) ↑

Side Talk Rejection 정확도 (%) ↑

SC · beamformed



MC · 채널 0 + beamformed



MC는 두 채널을 interleave · 원시 전체 배열의 동시 입력은 아님


이 추가 채널·시스템 학습 조건에서 실제 응답 대상 판단이 개선됐다.

연구사의 공통 질문은 공간 정보가 어디서 사라지는가다

연구에서 바뀐 질문	정보가 넘어가는 경계	필요한 확인
BAT: 위치에서 관계 질문으로	$E \rightarrow P \rightarrow LM$	질문만 / 오디오 추가
DSPAST · OWL: 무엇을 배울까	물리 단서·기하 지도 $\rightarrow E$	E 판독과 QA 구분
Motion: 예측을 언어로 넘길까	속성 시계열 $\rightarrow JSON \rightarrow LM$	예측 오류·정보 누락
기존 Audio-LM: 공간을 더할까	의미 + 공간 $\rightarrow P \rightarrow LM$	공간 기여·의미 능력
Dynamic · ST: 이동을 묻는다면	사건·시간·음원 $\rightarrow$ 토큰	시간·정체성 결속

■ 각 논문을 무엇을 남기고, 무엇을 넘기며, 답에 무엇을 쓰게 했는가로 연결해 읽는다.

같은 장면에서 표현·토큰·답을 함께 검사한다



후속 실험 제안. 같은 모델·질문에서 알람만 이동하고 말소리는 유지한다.

좌표가 남고, token에 전달되고, 그 변화가 올바른 답으로 이어지는지 확인한다.


근거 부록

A 관측과 인코더 · B 의미와 공간의 정렬


C 공간 Audio-LM의 세부 설계 · D 시간 정보의 전달 · E 답변의 근거

사전학습 목표와 표현의 재사용 시험을 분리한다

마스킹 사전학습



후속 과제 판독




가중치 전달 후 고정

새 과제 정답으로 학습

고정 판독 프로토콜 · 실녹음 전체 미세조정은 별도 평가

마스킹은 학습 목표, 고정 인코더의 여러 과제 판독은 재사용을 확인하는 시험이다.

공간 단서를 목표로 배운 초기화는 잡음에서 시험한다



1시간 라벨 · 전체 미세조정

— GCC-PHAT-DNN

— GCC-DNN

— STFT-DNN

— SFD-CPSPhase

— SFD-GCC

— SFD-GCC-PHAT

— SFD-ILD+IPD


x: SNR (dB)

y: DOA MAE (°), 낮을수록 좋음


이 결과는 **공간 특징 사전학습 후 전체 미세조정**의 근거다. 고정 표현 판독과는 다르다.

배열 좌표와 후보 격자는 서로 다른 변경이다

같은 녹음 · 같은 배열




성긴 후보 격자



물어보는 방향 목록

촘촘한 후보 격자




물어보는 방향 목록

마이크 배열은 고정 · 질의할 후보 방향의 간격과 개수만 변경

배열 기하와 후보 방향 격자는 독립적으로 달라질 수 있다.

AGG-RL: 기하와 후보 방향의 정합



관측 경로

다채널 오디오 + 마이크 좌표

후보 경로

판정할 방향 격자

표현의 비교

두 표현의 정합으로 공간 응답 계산


후보 방향도 입력으로 받아 **후보별 공간 응답**을 계산한다.

기하 정합의 효과는 미노출 채널 수로 시험한다

Dynamic-U · 학습 4-12채널 / 시험 13-16채널

방향 MAE (°) ↓

ACC₁₀ (%) ↑




합성 · 최대 두 정지 화자 · Dynamic-S에서는 두 지표가 개선되지 않음

AGG-RL의 **DOA 재구현 안에서** 정합의 효과를 비교한다. 원형의 2D 위치 실험과는 구별한다.

입력 형식이 다르면 보존된 단서도 다르다


마이크 배열



서로 다른 위치의 관측

좌표: 방법별 입력 조건


바이노럴



두 귀의 관측

머리·귓바퀴의 전달 특성

FOA



1차 구면조화 성분


FOA는 구면조화 기저 성분 표현 · 기저의 형태는 설명용 단면

I 추론 때 주는 정보와 학습 정답을 만드는 정보를 나눠 읽는다.

좌표에 사건 이름까지 붙이면 SELD가 된다

사건 + 활성 시점

말소리




알람

방향과 결합

말소리

알람




활성일 때의 방향

고정 클래스 SELD · 정적 두 음원의 설명용 예시

■ 방향에 **사건 종류와 활성 시점**을 연결한 출력이 SELD다.

SELD 출력 형식의 설명용 예시. 실제 추정 결과가 아님.


위치 오차는 검출 범위와 함께 읽어야 한다



STARSS dev-test-sony: 실선이 평가 곡선. 점선은 검증, 녹색선은 기본 임계값 0.5.

임계값을 낮추면 재현율과 위치 오차가 함께 높아질 수 있다.

공간 단서를 목표로 정해 인코더를 학습한다



모델 입력

잡음·잔향이 섞인 바이노럴 STFT

사전학습 목표

clean 신호에서 계산한 공간 특징

후속 과제

특징 예측기를 버리고 DOA에
미세조정

오염된 입력으로 **깨끗한 비잔향 신호의 공간 특징**을 예측한다.

복원이 모든 물리량의 보존을 보장하지는 않는다

학습 방 8개 · 검증/시험 각 20개 방 · 4회 평균

TDoA MAE (samples) ↓

처음부터 지도학습




사전학습 + 전체 미세조정



C_{50} MAE는 1.14 → 1.21 dB로 증가 · 두 마이크 · 단일 정지 음성

TD0A 오차는 줄었지만 **모든 공간 지표가 개선된 것은 아니다.**

고정 표현의 위치 판독으로 재사용을 확인한다





합성 자연 장면 · 고정 인코더 + 지도 판독기. 중앙선: 중앙값, 상자: 사분위 범위.

I 중앙값과 퍼짐, 그리고 모델마다 다른 입력 조건을 함께 읽는다.

“뒤쪽의 알람”은 종류와 위치가 함께 맞아야 한다


공간 오디오

앞



뒤

알람



후보 문장

앞쪽 의 알람

뒤쪽 의 알람


소리 이름은 같고, 위치 표현은 다름

설명용 문장 후보 · 실제 모델의 정합 점수나 성공 예시가 아님


ELSA의 검색용 문장 정렬은 **사건과 위치를 함께 맞추는 요구**를 보여 준다.

의미와 공간을 따로 배우고 같은 음원에 연결한다

같은 소리를 다른 위치에



알람의 종류 유지




원래 caption과 공간 caption을 구별하는 분기 역할의 개념도

■ SALM은 **의미·공간을 각각 감독하고 결합**한다. LLM의 답변 생성과는 다른 정렬 문제다.


의미 정렬을 더하면 검색과 위치 판독이 어떻게 바뀌나

동일 SALM · 합성 FOA sClotho 평가

T2A R@1 (%) ↑



A2T R@1 (%) ↑



위치 오차 (°) ↓




- $L_{sCL} + L_{DOA}$
- 위 조건 + L_{CL}

■ 의미 정렬 loss의 기여를 본 결과다. LLM·LoRA의 효과를 측정한 표가 아니다.

의미 특징은 공간 경로의 어느 깊이에서 합칠까?

결합 위치만 비교



일반 오디오 태깅 사전학습 특징의 결합 위치 비교

AT2SELD는 의미·공간 특징의 결합 위치를 비교한다.

결합 위치의 효과도 학습 조건에 달려 있다



STARSS23 · Stage 3의 강한 dropout을 공유

Test SELD ↓

no-stitch · cs00



late-only · cs01




최적 validation 체크포인트로 test · 무결합 기준도 Stage 2보다 저하된 조건

이 Stage 3 조건에서 **late-only의 SELD 점수가 낮았다.**

언어 정렬도 실제 녹음에서 따로 검사한다

동일 ELSA · 문장 template와 audio embedding의 cosine similarity


4방향 정확도 (%) ↑



S-RWD: 실제 5개 방, 70개 샘플

이 작은 실녹음 평가에서 **합성보다 방향 분류 정확도가 낮았다.**

문장으로 고른 음원의 위치만 읽을 수 있나?



목표를 지정하는 입력

텍스트 및/또는 1초 예시 오디오

찾아야 할 출력

프레임별 목표 수 0 / 1 / 2와 DOA



SelectTSL의 출력은 **지정한 목표의 활성 수와 방향**이다.

목표 선택 뒤에도 IPD 경로의 기여가 남았다

text + 1초 audio cue 유지 · 같은 목표 입력 조건

MAE (°) ↓

F1 ↑



- Full
- IPD Enhancer 제거 · A1

MAE는 true positive만 계산 · F1과 함께 해석

목표 입력을 유지한 비교에서 **위상 정보 강화 경로의 기여**가 나타났다.

시간과 위치를 바꾼 문장은 다른 정답이다



사건 배치 재구성 · 화살표는 시간

■ 같은 두 소리도 **발생 순서·각 사건의 방향**이 달라지면 설명문과의 대응이 바뀐다.

순서·위치 정렬은 검색으로도 시험할 수 있다


두 합성 FOA 사건 · Global Text-to-Audio 검색 · $E_{\text{global}} \leftrightarrow T_{\text{st}}$ 의 cosine similarity

Global T2A R@1 (%) ↑

대조 학습만 · L_{cl}




전체 · $L_{\text{cl}} + L_{\text{st}} + L_{\text{local}} + L_{\text{consist}}$



전체 loss는 이 사건열 검색을 개선했으며, 연속 이동 추적은 별도 검증이 필요하다.


인코더가 같은 관측에서 과제별 특징을 고르게 한다



설계 재구성 · 가중 막대는 설명용

DSpAST는 **과제별 특징 선택**을 위해 사건·방향·거리의 정보 경로를 나눈다.


기하 지도는 인코더에 배우고, QA에서는 오디오만 읽는다



왼쪽: depth-RIR로 SAGE 학습. 오른쪽: 고정 음향 인코더 → projector → LLM.

기하 지도는 인코더 학습에, projector·LoRA는 그 표현을 사용하는 QA 학습에 쓴다.

좌우 음량만 주는 입력으로 무엇을 시험하나?



$L = g_L x \cdot R = g_R x$ · 같은 모노 원음, gain만 변경 · 두 BEATs 경로 고정


■ Dual-BEATs는 **제한된 좌우 레벨 차이**를 읽는 stereo 분류를 다룬다.

전처리가 단서를 바꾸면 점수도 달라진다

OLMo-3-7B + Dual-BEATs · Direction-First · 방향 정확도 (%) ↑


PA = 0.00

PA = 0.50



PA = 0.50에서는 크게 개선됐고, **PA = 0.00에서는 소폭 낮아졌다.**

방 기하 지도는 학습 때만 사용할 수 있다



왼쪽: 깊이 지도. 오른쪽: 청취자·음원 배치와 바이노럴 합성 장면.

깊이·RIR은 학습 지도, 질문에 답할 때의 관측은 바이노럴 오디오다.

학습할 때

깊이와 RIR 정답으로
기하적 제약을 제공

추론할 때

바이노럴 오디오와
언어 질문을 제공


사건 이름과 속성을 같은 음원에 묶는다



출력 형식 재구성 · 실제 생성 응답 아님

■ 각 소리의 내용·시간·공간 속성이 **같은 음원에 붙어 있어야** 설명이 일관된다.

속성이 맞아도 음원을 잘못 연결하면 틀린 답이다



원본 점·축 보존. 오른쪽 두 모델의 ◆·◇(1-4음원 평균)를 비교한다.

같은 RIR 조건에서 **Sci-Phi의 평균 TupleScore가 미세조정 기준선보다 높다.**

TupleScore · 0-1, 높을수록 좋음

What × Where × When의
기하평균

RIR 조건을 분리

◆ 합성 RIR


◇ 실측 RIR로 합성

이번에 읽는 비교

SELDNet+Phi-4 (MC, FT)

↔ Sci-Phi

지각·음원 결속·복합 질의를 나눠 측정한다



L1·지각

어떤 소리가 들리는가?

L2·음원과 속성 연결

어떤 소리가 그 위치에 있는가?

L3·질문 조건을 적용


청취자 방향이 바뀌면 답도 바뀌는가?

질문은 평가 정의를 설명하는 재구성이다.

원문 Fig. 4 장면 크롭 · 모델 입력이나 생성 결과가 아닌 개념 예시

세 층위는 **무엇을 평가하는지의 구분**이며, 모델이 출력하는 명시적 그래프가 아니다.


시간을 줄이기 전에 질문이 요구하는 정보를 정한다



설명용 시간축 · 실제 모델 예측 아님

순서·연속 이동·질의 구간은 서로 다른 시간 정보의 요구다.

교차하는 궤적에도 음원 정체성이 남아야 한다




좌우 위치-시간 재구성 · 실제 예측 아님

■ 각 순간의 위치를 넘어 **음원 정체성과 시간별 공간 상태**를 함께 유지해야 한다.


선택형 점수는 우연 기준부터 확인한다

세 선택지 MCQA · Gemini 2.5 Pro, 2025년 6월 업데이트 · AA (%) ↑


Localization



Relation



Trajectory




- 무작위 선택
- Gemini 2.5 Pro

AA: 반복 prompt 변형 실행의 평균 정확도

보고된 버전은 우연 기준보다 높았으며, **공간 과제마다 점수가 달랐다.**

현장에서는 말의 내용과 응답 대상이 같린다



기기에게 한 말

응답


주변 사람끼리의 말

비응답

WearVox Fig. 1의 side-talk rejection 문제 패널.

실제 착용자 장면에서는 **발화의 응답 대상**을 구별해야 한다.

고정 인코더 위에 선형 판독기만 학습한다




SARL 프로토콜 재구성 · 모델별 입력 형식 · 판독 20 epochs · 무작위 0, 완전 1

인코더는 고정하고, 공간 요인의 판독기만 학습한다.

단서를 제거하며 남은 반응의 원인을 좁힌다

GRAM-T · 20개 주파수 × SNR cell 중 유의한 반응 비율 (%)



Vocoded 75% = 50% + 25% · 정확도가 아닌 유의 반응 비율

파형 변형의 부수 변화까지 고려해 **가능한 설명의 범위**를 좁힌다.