



Intelligent
Information
Processing Lab.

서강대학교
지능정보처리 연구실

IIP LAB · SOGANG UNIVERSITY

공간 오디오 연구 계보

배열이 바뀌어도
공간 단서를 읽을 수 있는가

2023-2026 대표 문헌 세미나

배열이 바뀌어도 방향을 읽을 수 있을까?

달라지는 관측

채널 사이의 지연

마이크 배치가 바뀌면
위상차도 달라진다.

유지할 공간 의미

같은 음원의 방향

같은 좌표계에서는
같은 방향을 가리켜야 한다.

사고실험: 음원과 배열 중심을 고정한 원거리 단일 음원

오늘의 질문

방향 계산

위상차를 어떻게 방향으로 바꾸는가?

표현 재사용

다른 과제에서도 공간 정보를 읽을 수 있는가?

표현 검증

성능이 좋아졌다면, 무엇을 배운 것인가?

논문 비교 기준: **입력 · 학습 · 출력 · 적응 · 평가**

위상차가 방향이 되기까지

입력

파형

$x_1(t), x_2(t), \dots$

채널 비교

→ **교차 스펙트럼**

$X_i(f)X_j^*(f)$

상대 지연

→ **IPD / TDoA**

위상차 / 도달 시간차

기하 해석

→ **DOA**

음원의 도래 방향

지연을 방향으로 바꾸려면 **마이크 좌표**가 필요하다.

원거리 직접음 근사. 반사음과 잡음은 별도로 고려한다.

두 채널의 방향 모호성

배열 여러 쌍의 시간차


마이크 좌표와 여러 지연 제약을 함께 푼다.

사람 방향별 스펙트럼

머리·귓바퀴의 여과 특성이 앞뒤와 고도 모호성을 줄인다.

HRTF

청자마다 다른 머리 관련 전달함수



여러 방향에서 전달함수를 측정하는 3D3A 실험 장치

위치 추정

모델은 배열 기하를 어떻게 반영할까?

마이크 배치가 달라지면 같은 방향의 위상차도 달라진다.

학습하는 대상이 다르다

GCC / SRP / MUSIC

상관과 공간 응답을 계산한다

IPDnet


직접음의 위상차를 추정한다

Neural-SRP

위치별 응답을 학습한다

최종 방향이 같아도 **중간 표현**은 다르다.

Neural-SRP · 쌍별 응답의 합산



마이크 쌍마다


위상 특징
마이크 좌표
방 크기

고정 격자 예측

쌍별 응답을 합산해
음원의 위치를 찾는다.

후보 좌표는 학습 목표를 만드는 데 사용한다. 추론 입력에는 넣지 않는다.

AGG-RL · 후보 방향도 입력한다



세 가지 입력

다채널 오디오

마이크 좌표

후보 DOA 격자

공간 스펙트럼

각 후보 방향에 대한

응답을 계산한다.

배열 일반화의 세 축

채널 수

마이크 2개에서 N개로

배열 배치

학습에 사용한 배치에서 새로운 배치로

후보 격자

고정된 방향 목록에서 새로운 방향 질의로


세 조건을 **독립적으로** 바꿔 평가한다.

표현 학습

위치 추정 외의 과제에도 공간 정보를 쓸 수 있을까?


사전학습의 목표가 표현에 남는 정보를 결정한다.

표현 학습의 두 목표



MC-SimCLR

같은 녹음의 시간 구간을 가깝게
정지 음원을 가정한 대조 학습



CCSR

관측하지 않은 채널을 복원
채널 간 관계를 배우는 복원 학습


SFD · 깨끗한 특징을 학습 목표로

목표 깨끗한 바이노럴 신호의
 공간 특징

입력 잡음·잔향이 섞인 파형

전이 DOA 과제에서
 전체 미세조정


성능 향상은 사전학습의 유용성을 보여준다.




특징 증류 후 위치 추정에 적응하는 과정

GRAM · 여러 과제에서 같은 표현 읽기

A Naturalistic scene generation in a simulated MatterPort3D house



B Pre-training methodology of GRAM-Binaural




공간 과제와 일반 오디오 과제를 고정 인코더로 함께 평가한다.

공간 언어 모델

"오른쪽 뒤의 소리는 무엇인가?"


언어로 답하려면 소리의 종류와 방향을 함께 읽어야 한다.

BAT · 바이노럴 표현을 LLM에 연결



Spatial-AST의 표현을 **프로젝터**로 LLM 토큰에 연결한다.

PhaseCoder · 위치 표현을 공간 토큰으로



공간 토큰과 모노 오디오 토큰을 함께 LLM에 입력한다.

질문에 따라 입력과 출력이 달라진다

과제	대표 모델	읽어내는 정보
정적 장면	BAT · DSpAST	음원 종류 · 방향 · 거리
움직임	ST-AudioLM	소리 사건과 시간별 궤적
여러 공간 과제	OWL · Spatial-Omni	위치와 공간 관계에 대한 응답

바이노럴과 FOA, 서로 다른 평가셋의 점수는 **같은 순위로 비교할 수 없다.**

표현의 검증

성능이 좋아졌다면, 무엇을 배운 것일까?

인코더, 판독기, 추가 학습의 기여를 구분해야 한다.

인코더 적응과 판독기 용량

평가 방식	인코더	확인하는 것
선형 탐침	고정	선형으로 읽히는 정보
소형 MLP	고정	비선형으로 읽히는 정보
전체 미세조정	업데이트	과제 적응 후의 성능
LLM 연결	방법별 상이	해당 학습 조건의 시스템 성능

무엇을 고정하고 무엇을 학습했는가?

학습에서 무엇을 제외했는가

01 콘텐츠

화자 · 클립 · 소리 종류

02 음향 환경


HRTF 청자 · 방 · 충격응답

03 센서

배열 배치 · 채널 수 · 장치


04 녹음 조건

시뮬레이션 · 실제 녹음



BiDepth의 기하 정보와 바이노럴 장면 생성

SARL · 음원과 방 정보의 접근성




음원 요인의 점수가 더 높다

고정 인코더
선형 탐침
단일 음원 합성 장면

방 정보의 완전한 부재를
뜻하지는 않는다.

무작위 기준으로 정규화한 점수. 음원 종류·위치와 방 요인을 비교한다.

SARL · 민감도와 접근성



많이 변한다고
잘 읽히지는 않는다

음원·방 요인을
통제해 바꾼 뒤
표현 거리를 측정한다.

앞 장의 판독 점수와 함께 해석한다. 큰 표현 변화가 높은 판독 성능을 보장하지는 않는다.

BMLD · 표적음의 위상만 바꾼다


양쪽 귀에 같은 잡음. 표적음만 한쪽에서 반전.

조건	왼쪽 귀	오른쪽 귀
N_0	잡음 n	같은 잡음 n
S_0N_0	$s + n$	$s + n$
$S\pi N_0$	$s + n$	$-s + n$

두 혼합음의 표현이 **잡음 기준에서 떨어진 거리**를 비교한다.

BMLD: 양이 마스킹 레벨 차이. 여기서는 임베딩 거리 비율을 dB로 측정한다.


BMLD · 모델마다 다른 위상 반응



500 Hz, SNR -14 dB: **GRAM-T +2.1 dB**, Spatial-AST +6.8 dB, EC 기준 +15.7 dB

임베딩 거리 비율이다. 사람의 청취 역치와 같은 지표가 아니다.

BMLD · 다른 단서의 기여



위상 반응에는
다른 단서도 섞인다

스펙트럼 단서 제거
시간 단서 제거

각 조작 뒤의
표현 변화를 비교한다.

유의한 변화가 나타난 조건의 비율. 역방향 반응도 포함하므로 정확도로 읽지 않는다.

처음 질문으로 돌아오면

배열이 바뀌어도 공간 단서를 읽을 수 있는가?

기하 조건부 위치 추정

새 배열에서도 방향을 구하는가

사전학습 표현

다른 과제에서도 정보를 읽는가

공간 언어 시스템

음향 단서를 바꾸면 답도 맞게 변하는가

표현은 위상 변화와 배열 기하의 관계를 보존하는가?

연구 가설 · 지연과 기하의 관계

검증 전 연구 제안

위상 확보

다채널 인코더

상대 위상 단서를 남긴다

관계 판독

→ **마이크 쌍 표현**

쌍 사이의 지연을 읽는다

기하 해석

→ **기하 연산 Q**

지연을 방향과 연결한다

인코더를 고정한 채 새로운 배열에서도 이 관계를 유지할 수 있는가?

네 실험으로 가설을 검증한다

01

고정 표현

선형 탐침과 소형 MLP로
TDoA·DOA를 읽을 수 있는가?

03

지연 개입

알려진 $\Delta\tau$ 에 맞춰
예측이 변하는가?

02

새 배열

채널 수·배치·격자가 바뀌어도
오차가 유지되는가?

04

파형과 잠재 개입

같은 개입에 대응하는
출력 변화가 나타나는가?

검증 계획. 기준선: GCC-PHAT/SRP, 학습 전 인코더. 동일한 학습량과 조건별 불확실성을 보고한다.

공간 단서를 읽었다는 근거

신호와 기하

지연을 배열 좌표에 맞춰 해석한다

표현과 판독

고정한 모듈과 학습한 모듈을 구분한다

개입과 일관성

바꾼 단서에 맞게 표현과 출력이 변한다

정답률에 더해,
단서 변화에 대한 반응을 확인한다.

주요 용어

용어	의미	발표에서의 역할
IPD / ILD	채널 간 위상차 / 레벨차	위치와 관련된 관측 단서
TDoA / DOA	도달 시간차 / 음원의 도래 방향	상대 지연과 최종 방향을 구별
GCC-PHAT	위상 변환으로 가중한 일반화 상호상관	채널 간 지연 추정 기준선
SRP / MUSIC	조향 응답 전력 / 다중 신호 분류법	응답 합산 / 부분공간 기반 위치 추정
CPS / HRTF	교차 전력 스펙트럼 / 머리 관련 전달함수	채널 간 관계 / 청자별 여과 특성
RIR / BRIR	방 충격응답 / 바이노럴 방 충격응답	반사음·잔향을 포함한 전달 특성
바이노럴 / FOA	두 귀 신호 / 1차 앰비소닉스	서로 다른 공간 오디오 표현 형식
탐침 / LoRA	고정 특징의 판독기 / 저랭크 적응	평가 시 어디를 학습했는지 구별

PHAT와 지연 추정

교차 스펙트럼

$$X_1 X_2^* = A_1 A_2 \cdot \exp[j(\varphi_1 - \varphi_2)]$$

$$\angle(X_1 X_2^*) = \varphi_1 - \varphi_2 = \text{IPD}$$

PHAT + 역푸리에 변환

$$\rightarrow \Phi_{12}(f) = X_1 X_2^* / |X_1 X_2^*|$$

$$\hat{\tau} = \arg \max_{\tau} \mathcal{F}^{-1}\{\Phi_{12}\}(\tau)$$

크기가 아니라 **주파수별 위상 변화**가 같은 지연값을 가리키는 지점을 찾는다.

공간 표현의 판독기

공간 표현

$z(x, \text{배열 기하})$

→ 위치 추정기

후보 방향 분류 · 좌표 회귀

→ 탐침 · 디코더

요인 접근성 · 물리 법칙

→ 언어 모델

질의응답 · 그라운드링 · 궤적 추론

임베딩의 공간성을 말하려면, **누가 얼마나 적응해 무엇을 읽었는지** 밝혀야 한다.

판독기마다 다른 검증 가설

LINEAR PROBE

선형 탐침

$$\hat{y} = Wz + b$$

공간 요인을
선형 변환만으로 읽을 수 있는가?

SMALL MLP

소형 MLP

$$\hat{y} = W_2\sigma(W_1z)$$

약한 비선형 변환만으로
읽을 수 있는가?

PHYSICS-AWARE DECODER · 연구 제안


물리 디코더

$$Q(z_i, z_j; m_i, m_j) \rightarrow \tau_{ij}$$

마이크 쌍의 관계가
기하 법칙에 맞는가?


판독기의 용량을 밝혀야 '**읽을 수 있다**'와 '**물리 법칙에 맞게 정리돼 있다**'를 구분할 수 있다.

DSPAST와 OWL



DSPAST · 요인 분리

사건 · 방향 · 거리별로 표현을 나눈다.



OWL · 기하 정렬

깊이·RIR은 학습 지도 정보다. 추론 입력은 바이노럴 오디오다.

공간 오디오 문헌 지도

위치 추정	방향을 직접 구한다	GCC/SRP/MUSIC · IPDnet · Neural-SRP · AGG-RL
공간 표현	공간 정보를 다시 쓴다	MC-SimCLR · CCSR · SFD · GRAM
언어 모델	공간을 묻고 설명한다	BAT · DSpAST · PhaseCoder · OWL · ST-AudioLM · Spatial-Omni
검증	SARL은 고정 표현의 요인 접근성을, BMLD는 양이 위상 조건에 대한 표현 반응을 비교한다.	

공통 문제에 따른 분류다. 직접적인 후속 관계나 모든 평가가 모든 입력 형식에 그대로 적용된다는 뜻은 아니다.

위치 추정과 표현 학습


연구	목표	입력	학습	출력	적응	핵심 평가
IPDnet	위치 추정	다채널	DP-IPD	음원 IPD	과제 학습	이동 · 새 배열
Neural-SRP	위치 추정	쌍별 위상+좌표+방 크기	신경 SRP	위치	과제 학습	시물 → 실녹음
AGG-RL	위치 추정	오디오+기하+격자	격자 정합	스펙트럼	과제 학습	기하 · 채널 · 격자
MC-SimCLR	표현 학습	다채널	대조 학습	임베딩	탐침 / 미세조정	사건 종류 · 방위각
CCSR	표현 학습	다채널	채널 복원	임베딩	선형 / 미세조정	모의 · 실제 과제
SFD	강건한 DOA	바이노럴	특징 증류	초기 인코더	전체 미세조정	HRTF · 잡음 · 잔향
GRAM	범용 표현	다채널	마스킹 AE	임베딩	고정 탐침 / 미세조정 비교	일반 · 공간 · 실제

언어 시스템과 진단 프로토콜

연구	목표	입력	학습	출력	적응	핵심 평가
BAT	공간 QA	바이노럴	지시 학습	텍스트	프로젝터+LoRA	추론 QA
DSpAST	공간 QA	바이노럴	사건·방향·거리 분리	텍스트	LLM 연결	요인 QA
PhaseCoder	DOA + QA	다채널+기하	위상 토큰	좌표 / 텍스트	LLM 연결	새 배열 기하
OWL	3D QA	바이노럴	깊이·RIR 지도	텍스트	LLM 연결	BiDepth + 전이
ST-AudioLM	궤적 QA	FOA 시퀀스	사건+움직임	토큰	시스템 학습	동적 QA
Spatial-Omni	통합 QA	FOA	SO-Encoder	텍스트	시스템 학습	16개 하위 과제
SARL	표현 진단	통제 합성 장면	선형 탐침	요인별 점수	인코더 고정	접근성 · 민감도
BMLD	단서 진단	양이 위상 조건	추가 학습 없음	거리 비율	인코더 고정	위상 반전 · 단서 제거

OWL의 깊이·RIR은 학습용 지도 정보다. 추론에는 바이노럴 오디오를 사용한다.

Neural-SRP · 실제 녹음의 응답




같은 녹음,
다른 공간 응답

위: NeuralSRP+
아래: SRP

주황색 x는 음원,
파란 점은 마이크다.

원문의 실제 녹음 예시. 하나의 예시 그림으로 모든 조건의 성능을 대표하지 않는다.

AGG-RL · 후보 방향별 응답



4채널, 2음원 장면

후보 방향별
공간 스펙트럼을
비교하는 예시

공식 프로젝트의 예시 그림. 일반화 범위는 논문의 실험 조건으로 판단한다.

위치 추정 · 표현 학습 · 데이터

1. Knapp & Carter. **The Generalized Correlation Method for Estimation of Time Delay.** IEEE TASSP, 1976.
2. Grinstein et al. **The Neural-SRP Method for Positional Sound Source Localization.** arXiv:2403.09455, 2024.
3. Wang et al. **IPDnet: A Universal Direct-Path IPD Estimation Network for Sound Source Localization.** arXiv:2405.07021, 2024.
4. Baek et al. **Physics-Informed Audio-Geometry-Grid Representation Learning for Universal Sound Source Localization.** ICLR 2026.
5. Jiang et al. **Exploring Self-Supervised Contrastive Learning of Spatial Sound Event Representation.** arXiv:2309.15938, 2023.
6. Yang & Li. **Self-Supervised Learning of Spatial Acoustic Representation with Cross-Channel Signal Reconstruction and Multi-Channel Conformer.** arXiv:2312.00476, 2023.
7. Bovbjerg et al. **Learning Robust Spatial Representations from Binaural Audio through Feature Distillation.** arXiv:2508.20914, 2025.
8. Yuksel et al. **GRAM: Spatial General-Purpose Audio Representations for Real-World Environments.** arXiv:2506.00934v5, 2025–2026.
9. Chen et al. **SoundSpaces 2.0: A Simulation Platform for Visual-Acoustic Learning.** NeurIPS, 2022.
10. Evers et al. **The LOCATA Challenge.** IEEE/ACM TASLP, 2020.
11. Princeton 3D3A Lab. **3D3A HRTF Database.** CC BY 4.0.
12. Biswas et al. **BiDepth dataset** in OWL, arXiv:2509.26140, 2025.

언어 모델 · 평가

13. Zheng et al. **BAT: Learning to Reason about Spatial Sounds with Large Language Models.** arXiv:2402.01591, 2024.
14. Wilkinghoff & Tan. **DSpAST: Disentangled Representations for Spatial Audio Reasoning with Large Language Models.** arXiv:2509.13927, 2025.
15. Dementyev et al. **PhaseCoder: Microphone Geometry-Agnostic Spatial Audio Understanding for Multimodal LLMs.** arXiv:2601.21124, 2026.
16. Biswas et al. **OWL: Geometry-Aware Spatial Reasoning for Audio Large Language Models.** ICLR 2026.
17. Oh et al. **Spatio-Temporal Audio Language Modeling for Dynamic Sound Sources.** arXiv:2606.14141, 2026.
18. Zhu et al. **Spatial-Omni: Spatial Audio Understanding Integration in Multimodal LLMs via FOA Encoding.** arXiv:2606.10738, 2026.
19. Chen et al. **Probing Spatial Structure in Pretrained Audio Representations.** arXiv:2606.05544, 2026.
20. Chen, Yu & He. **Spectro-Temporal Interference Confounds Phase Encoding in Spatial Audio Foundation Models.** arXiv:2606.14820, 2026.
21. Grumiaux et al. **A Survey of Sound Source Localization with Deep Learning Methods.** JASA, 2022.
22. Grinstein et al. **Steered Response Power for Sound Source Localization: A Tutorial Review.** EURASIP, 2024.

대표 논문을 중심으로 그린 지도다. 모든 위치 추정·SELD·공간 LLM 연구를 망라하지는 않는다.